

Universidade do Minho

LEI — Licenciatura de Engenharia Informática

Processamento de Linguagens

Trabalho pratico 1

Paulo Araujo - a58925, Orlando Costa - a67705, Rui Oliveira - a67661







Braga, 25 de março de 2015

Resumo

Este relatório descreve a resolução de um conjunto de exercícios propostos, que consistem no desenvolvimento de programas na linguagem C com o auxílio de geradores de filtros de texto, como o Flex. Para cada problema é realizada uma breve análise sobre o trabalho efetuado, as decisões que lideraram o seu desenvolvimento e as estruturas implementadas, assim como uma explicação do seu funcionamento.

Os problemas resolvidos consistem no desenvolvimento de filtros de texto que:

- processa um ficheiro XML com descrições de fotografias e gerar um álbum HTML.
- processa de um ficheiro XML anotado com tags Enamex e gera páginas HTML apresentando as "pessoas", "países", "cidades"e organizações nele identificadas.
- processa vários ficheiros de texto, compostos por letras de canções, e gera documentos em LATEX para cada uma delas.

Para cada problema é apresentado o código em linguagem C e as expressões regulares desenvolvidas, sendo estes suportados por exemplos e devidos resultados.

Conteúdo

1	Intr	rodução	D	3
2	Mu	seu da	Pessoa — tratamento de fotografias	4
	2.1	Analis	e e Especificação	4
	2.2		nentação	4
		2.2.1	Estrutura de dados	4
		2.2.2	Filtro de Texto	5
		2.2.3	Funcionamento	6
	2.3	Testes	realizados	6
3	Pro	cessam	nento de Entidades Nomeadas	7
	3.1		e e Especificação	8
	3.2		nentação	8
	_	3.2.1	Estrutura de dados	8
		3.2.2	Filtro de Texto	ç
		3.2.3	Funcionamento	10
	3.3	Testes	realizados	10
4	Pro	cessam	nento de ficheiros com Canções	12
•	4.1		e e Especificação	$\frac{12}{12}$
	4.2		nentação	12
	1.2	4.2.1	Estrutura de dados	12
		4.2.2	Filtro de Texto	13
		4.2.3	Funcionamento	13
		4.2.4	Testes realizados	14
5	Cor	ıclusão		15
•	001	lorasao		
6	Ane			16
	6.1	Museu	da Pessoa — tratamento de fotografias	16
		6.1.1	Filtro de Texto	16
		6.1.2	Estrutura de dados	17
		6.1.3	Cabeçalho ficheiro C	21
	6.2	Proces	samento de Entidades Nomeadas (Enamex)	22
		6.2.1	Filtro de Texto	22
		6.2.2	Estrutura de dados	26
		6.2.3	Cabecalho ficheiro C	29

	6.2.4	Testes
6.3	Proces	ssamento de ficheiros com Canções
	6.3.1	Filtro de Texto
	6.3.2	Estrutura de dados
	6.3.3	Cabeçalho ficheiro C
	6.3.4	Testes

Introdução

O presente projeto enquandra-se na unidade curricular de Processamento de Linguagnes do curso de Licenciatura em Engenharia Informática da Universidade do Minho. O projeto pretende aumentar as capacidades com as expressões regulares, desenvolvendo processadores de linguagens regulares utilizando o gerador de filtros de texto Flex. Para isso foram selecionados 3 exercícios dentro de um grupo de 8 exercícios, são eles: 2.1 Museu da Pessoa — tratamento de fotografias, 2.2 Processamento de Entidades Nomeadas (Enamex) e 2.5 Processamento de ficheiros com Canções.

Museu da Pessoa — tratamento de fotografias

Neste problema é pretendido que, a partir de um ficheiro XML, seja criado um filtro de texto capaz de interpretar informação relativa às entrevistas feitas para construção o Museu da Pessoa. Com toda essa informação, deverá ser criado um álbum em HTML possuidor de um índice, ordenado alfabeticamente, contendo todos os nomes de pessoas presentes no álbum. Além disso, cada elemento do índice deverá estar referenciado para a página que contém todas as fotos da respetiva pessoa. Relativamente às fotos, essas deverão estar ordenadas cronologicamente e a descrição da foto deverá ser o seu título/cabeçalho.

2.1 Analise e Especificação

Após a análise do que é pedido no enunciado e de alguns dos *Datasets*, foi possível verificar qual a informação essencial a retirar do ficheiro *XML*. Além disso, como não é regra que as fotos e pessoas presentes no ficheiro *XML* estejam já na ordem pretendida, será necessário que toda a informação seja armazenada em estruturas de dados. O nome do ficheiro *HTML* resultante, poderá ser dado como argumento e caso não seja, por omissão será *Album Gerado.html*. Além deste ficheiro, serão gerados tantos ficheiros *HTML* quantas as pessoas presentes no álbum. Esses ficheiros serão denominados numericamente (1.html,2.html,...) à medida que novos nomes são encontrados. Os ficheiros anteriormente referidos apenas serão gerados no final da leitura e filtragem de ficheiro *XML*.

2.2 Implementação

2.2.1 Estrutura de dados

De forma a dar seguimento ao que foi especificado na secção 2.1, foi necessária a criação de uma estrutura de dados que sirva de suporte aos dados recolhidos. Sendo assim, optamos por criar uma estrutura denominada photo_node que terá o formato de uma árvore binária e servirá para

armazenar toda a informação relativa a cada descrição de fotos encontrada no ficheiro XML. Nesta estrutura serão guardados o nome do ficheiro que contém a foto, a data e o local em que esta foi tirada, a sua descrição e o nome das pessoas nela presentes. A inserção de fotos nesta árvore será ordenada relativamente à sua data. Além desta estrutura, também criamos outra, denominada person_node, com o objetivo que esta guarde toda a informação acerca das pessoas presentes no álbum. Esta estrutura tem o formato de uma lista ligada e guardará informação como o nome da pessoa, assim como o nome do ficheiro da sua página HTML e terá ainda um apontador para uma estrutura photo_node em que será armazenada toda a informação relacionada com as suas fotos. Finalmente, criamos uma estrutura Album que apenas conterá um apontador para uma estrutura person_node, onde estará a informação relativa às pessoas nele presente, e um contador que servirá para contar o número de pessoas presentes no álbum. O contador servirá de auxílio na criação dás páginas HTML numeradas referidas na secção 2.1.

2.2.2 Filtro de Texto

Um dos objetivos deste trabalho prático é a utilização de geradores de filtro de texto, como o *Flex*. Sendo assim, foi criado um ficheiro Flex que permite encontrar determinados padrões de expressões regulares e executar uma determinada ação para cada uma delas.

No ficheiro referido, podemos encontrar algumas instruções em linguagem C como a inclusão de ficheiros de cabeçalhos (headers, .h) e a declaração de variáveis. De seguida, são definidas as expressões regulares e as respetivas ações que se pretendem realizar no caso da identificação positiva do referido padrão:

\<foto[\t]+[a-zA-Z]+=\".*\" A partir da análise do ficheiro XML exemplificado no enunciado, foi possível verificar que a descrição de uma foto começa com o nome do ficheiro que a contem da seguinte forma: <foto ficheiro="ficheiro.jpg">. Sendo assim, quando este padrão é encontrado, é inicializado um photo_node com o nome encontrado entre as aspas. O nome é obtido retirando da expressão apenas o que se encontra à frente da primeira ocorrência de aspas e atrás da ocorrência seguinte.

\\quando[\t]+[a-zA-Z]+=\"[0-9]{4}(.|-)[0-9]{2}(.|-)[0-9]{2} De seguida pretendemos encontrar a data em que a foto foi tirada. A partir do exemplo do enunciado, verificamos que a data é descrita da seguinte forma: \quando data="1961-01-15"/>. Sendo assim, pretendemos encontrar todas as expressões no formato referido, com a possibilidade que a data esteja separada por pontos em vez de traços. A obtenção da data faz-se retirando apenas o que se encontra à frente da primeira ocorrência de aspas.

\quem>[\t\na-zA-ZÀ-û,\"0-9;:]+ Um padrão essencial a encontrar é o nome das pessoas presentes na foto. Esses nomes devem estar descritos da seguinte forma:

<quem>Ana de Lourdes de Oliveira Chamine; Antonio Oliveira Machado/quem>

Nesta fase, optamos por não separar ainda os nomes por tokens porque será mais útil fazê-lo apenas quando a descrição da foto estiver completa. Sendo assim, apenas retiramos tudo o que esteja entre '>' e '<' e adicionamos à estrutura que contem a descrição da foto.

\<onde>[\t\n0-9a-zA-ZÀ-û.,;:\"]+< Continuando com a análise do exemplo do enunciado, verificamos que uma foto pode ter descrito o local em que esta foi tirada:

<onde>Casa Machado, Afurada, Vila Nova de Gaia</onde>

Ora, quando este padrão é encontrado, só é necessário guardar o que está entre '>' e '<', assim como no caso anterior.

\<facto>[\t\n0-9a-zA-Z\hat{A}-\hat{u}.;;\"]+< Finalmente, o último campo necessário para a descrição da foto \u00e9 o facto que esta representa: <facto> Os noivos cortam o bolo de casamento</facto>. O que \u00e9 essencial retirar neste caso \u00e9 o mesmo que nos casos anteriores, ou seja, apenas o que se encontra entre '>' e '<'.

\<\foto> Sempre que é encontrado o padrão que finaliza a descrição de uma foto, </foto>, é necessário adicionar o photo_node criado a todos os respetivos person_node das pessoas que se encontram na descrição da foto. É nesta fase que os nomes das pessoas presentes na foto é separado e identificado. Finalmente adiciona-se a descrição da foto a todas as pessoas nela presente.

. | \n Este padrão apenas é utilizado para indicar que sempre que é encontrado qualquer outro byte ou \n, deve ser ignorado.

2.2.3 Funcionamento

Antes do filtro de texto ser aplicado ao ficheiro XML é invocada a função init que inicializa uma variável static Album. Inicializada esta variável, é possível aplicar o filtro de texto. À medida que a informação do ficheiro XML é filtrada, são invocadas funções que tratam e guardam na estrutura a informação recolhida. Sempre que é encontrada uma expressão que defina o início de uma descrição de uma foto, a informação relativa ao nome da foto é recolhida e é invocada a função initPhoto que trata de alocar o espaço necessário para a informação que virá a ser recolhida posteriormente. Do mesmo modo, sempre que é encontrada uma expressão que identifique a data, a localização, a descrição ou as pessoas presentes na foto, são invocadas funções capazes de tratar e armazenar essa informação. As funções referidas são setDate, setLoc, setFact e setWho, respetivamente. Sempre que não seja possível identificar uma destas características anteriores, estas ficam com os seus valores por defeito, ou seja, caso uma foto não tenha a tag <quem>, o seu campo correspondente na estrutura ficará preenchido com "Desconhecidos". Finalmente, quando é encontrada a expressão que define o final da descrição de uma foto, é invocada a função que trata de inserir a informação da nova foto na estrutura Album. Depois de tratada toda a informação, são invocadas funções auxiliares que criam e preenchem o(s) ficheiro(s) HTML necessários.

2.3 Testes realizados

<alguns exemplos>

Possíveis exemplos de aplicação deste filtro de texto:

- cat\ <inputFile>\ |\ ./play\ <output1.html>\
- cat\ <inputFile>\ |\ ./play\

Processamento de Entidades Nomeadas

Entidades nomeadas são "elementos atómicos em texto" pertencentes a categorias predefinidas tais como nomes de pessoas, organizações, localizações, quantidades, etc. Assim, Processamento de Entidades Nomeadas (PEN) é a tarefa de identificar estas entidades. Embora as categorias das entidades nomeadas serem predefinidas, existem várias opiniões sobre que categorias deve ser consideradas entidades nomeadas e quão abrangentes estas categorias devem ser. Por convenção, tags "ENAMEX" são utilizadas para nomes, tags "NUMEX" são utilizadas para entidades numéricas, e tags "TIMEX" são utilizadas para entidades temporais.

Neste exercício iremos apenas processar entidades com a tag "ENAMEX", na forma:

- <ENAMEX TYPE="PERSON">Francisco de Vilela Barbosa</ENAMEX> (Pessoa)
- <ENAMEX TYPE="LOCATION" SUBTYPE="COUNTRY">Portugal</ENAMEX> (Localização, País)
- <ENAMEX TYPE="LOCATION" SUBTYPE="CITY">Rio de Janeiro</ENAMEX> (Localização, Cidade)
- <ENAMEX TYPE="ORGANIZATION">Universidade do Minho</ENAMEX> (Organização)

Como exercício extra iremos também abordar as entidades na forma:

• <ENAMEX TYPE="LOCATION"> Santo Novo </ENAMEX> (Localização não específica)

Todas as outras tags irão ser ignoradas.

O processamento de entidades nomeadas, apesar de ser aparentemente uma tarefa simples, enfrenta um dado numero de desafios. As entidades podem tornar-se difíceis de encontrar, e uma vez encontradas, difíceis de classificar. Localizações e nomes de pessoas podem ser as mesmas, e seguir estilos similares de formatação.

3.1 Analise e Especificação

Uma breve leitura do problema permite-nos entender algumas das funcionalidades necessárias, sendo estas definidas como:

- Necessidade de ordenação e não repetição na listagem de pessoas(alínea a):
 - A alínea A do problema requer a listagem de todas as pessoas identificadas, sem repetições. Este informação refere-se então às tags do tipo:

<ENAMEX TYPE="PERSON">...</ENAMEX>.

Por forma a armazenar e ordenar adequadamente toda a informação acerca das Pessoas, é necessária a utilização de uma estrutura capaz de suportar esta informação.

- Listar os países e cidades marcadas (alínea b):
 - Apesar de não estar especificado no enunciado, o grupo propôs uma implementação na qual seria possível associar cidades a certos países. Compreendemos que este tipo de implementação, para grande parte dos casos, não é viável e pode tornar a informação apresentada incoerente. No entanto, no intuito de aprender e aumentar o desafio proposto, decidimos que cidades mencionadas após países e antes de pontos finais pertenciam a esses países. Esta informação é também armazenada na estrutura implementada.
- Listar as organizações (alínea c):
 - Similarmente à alínea A, a alínea C requer a listagem de todas as organizações identificadas. Esta informação refere-se então às tags do tipo:

<ENAMEX TYPE="ORGANIZATION">...</ENAMEX>

E está implementada de forma similar à listagem de pessoas.

- Apresentar os resultados em formato HTML:
 - Por forma a visualizar facilmente os resultados do processamento do texto, estes são apresentados em formato HTML através da implementação de funções capazes de transformar a informação contida nas estruturas em documentos de texto com o formato requerido.

3.2 Implementação

3.2.1 Estrutura de dados

Com o intuito de cumprir todos os requisitos estruturais definidos anteriormente, foi desenvolvida uma estrutura de dados única capaz de armazenar todos os dados necessários. Assim, escolhemos implementar uma árvore binária de procura, na qual os nodos possuem a informação a guardar sobre a forma de array de caracteres. A escolha desta estrutura facilita a ordenação alfabética dos diversos nomes que possamos processar, e é de implementação relativamente simples. Creemos ser superior a outras estruturas tais como listas ligadas cuja implementação, apesar de mais

simples, torna-se mais complexa quando é necessária a ordenação dos seus elementos (O(N)) e a tabelas de hash cuja implementação é mais complexa, sendo que para elevadas quantidades de dados possuem ainda a necessidade de reHashing e garbage colection.

```
<-tree.png-> ???
```

Para casos em que apenas é necessário o armazenamento da entidade, sem qualquer tipo de associação, uma árvore com dois apontadores (esquerda e direita) e com a capacidade de armazenar a informação (array de caracteres) bastaria para abordar todos os casos. No entanto, de forma a armazenar a possível associação entre os países e as suas cidades, modificamos a árvore previamente referida, e adicionamos-lhe um apontador extra, que poderá ser visto como o apontador para a raiz de uma nova árvore, constituída por todas as cidades que pertencem a um dado país. Como curiosidade, adicionamos também um inteiro em cada nodo que servirá como contador para todas as ocorrências de um dado elemento. Todo o código referente a esta estrutura encontra-se implementado no ficheiros "tree.c"e "tree.h"e pode ser consultado em anexo.

3.2.2 Filtro de Texto

De forma a processar as tags pertencentes a pessoas/organizações, foram criadas expressões regulares capazes de identificar essas tags. Assim, foram implementadas as seguintes expressões regulares para pessoas/organizações, assim como abreviaturas que facilitam a sua leitura e compreensão:

- pessoas: {enamex}{person}{pal}{eclose}
- organizações:{enamex}{org}{pal}{eclose}
- localizações gerais: {enamex}{loc}{pal}{eclose}
- cidades: {enamex}{loc}{subcity}{pal}{eclose}

sendo que as abreviaturas mencionadas correspondem a:

• Palavra

```
{pal} [a-zA-ZO-9Q-\tilde{N}\tilde{A}-\hat{u}]+
```

• Tag Enamex

```
\{enamex\} \ \ (?i:enamex)[ \t]+(?i:type)=
```

• Tag de fecho

```
\{eclose\} \ \ (?i:enamex)[ \t]*\
```

• Elemento "Organization"

```
{org} \"[ \t]*(?i:organization)[ \t]*\"[ \t]*\>
```

• Elemento "Person"

De notar a capacidade das expressões regulares identificarem tags definidas tanto em letra maiuscula como minuscula, sendo também tolerantes à quantidade de espaços ou tabs presentes entre elementos destas. De forma a implementar a capacidade de associar cidades a um dado país, foram utilizados "operadores de contexto", de forma a que caso seja detectado uma tag correspondente a um país, o analisador entre no contexto não exclusivo (%s)country, e associa as seguintes tags correspondentes a cidades ao país em causa. Caso seja detetado um ponto final, o analisador lexico abandona esse contexto e continua a processar em contexto geral.

Nota: Esta foi uma funcionalidade assumida, pelo que poderá nem sempre ter sucesso e fazer as corretas associações.

Assim as expressões regulares correspondentes a localizações/países/cidades foram definidas na forma:

• paises:

```
{enamex}{loc}{subcountry}{pal}{eclose}
```

sendo que as abreviaturas mencionadas correspondem a:

```
• Elemento "Country" {subcountry} (?i:subtype)=\"[\t]*(?i:country)[\t]*\"[\t]*\>
```

• Elemento "City" {subcity} (?i:subtype)=\"[\t]*(?i:city)[\t]*\"[\t]*\>

Estas expressões devem encontrar-se no topo de todas as outras, devido à precedência que possuem sobre elas.

3.2.3 Funcionamento

No cabeçalho do ficheiro flex são declarados todos os apontadores referentes às estruturas onde irá ser armazenada a informação. Existe um apontador para cada tipo de estrutura, nomeadamente: pessoas, paises, cidades, organizações e outras localizações. São também declarados dois apontadores para arrays de caracteres que irão auxiliar o processamento das expressões capturadas. Após início do programa, é efetuada a chamada ao analisador léxico, responsável por capturar os dados referentes às expressões definidas. Cada vez que este efetua uma captura, estes dados são processados, sendo inseridos na estrutura correspondente, sendo que caso necessário lhes são retirados os espaços em branco que possam ter antes e depois da seu conteúdo, por forma a evitar inconsistência de dados. Após o término da leitura do input em questão, todos os dados presentes nas estruturas são escritos nos ficheiros HTML correspondentes, estando estes interligados através de hiperligações (tags). Cada estrutura (tipo de entidade) é escrita em ficheiro através da função treeToHTML (implementada no ficheiro tree.c), responsável por receber como parâmetros um apontador para estrutura e um identificador de ficheiro (previamente declarado), e transferir a informação para o ficheiro no formato adequado.

<- constituição do programa.png ->

3.3 Testes realizados

Estão documentados neste secção 3 testes realizados ao autómato, utilizando como input os ficheiros que se encontram em anexo: 6.3.4, 6.3.4 e 6.3.4.

Teste n^o 1

Teste focado na funcionalidade de associar diversas cidades a um dado país. Como é possível verificar em anexo, o resultado é uma conexão entre "Portugal"e algumas das suas cidades.

Teste nº 2

Teste exemplificado no enunciado. Processado de acordo com o esperado (exemplo da página referente aos locais).

Teste nº 3

Teste obtido de um caso real, e focado nas tags de organizações. Resultado correto.

Processamento de ficheiros com Canções

Neste problema era pretendido que fosse criado um filtro de texto capaz de interpretar ficheiros com letras de músicas, e fosse gerado um ficheiro latex para cada música encontrada, contendo a informação processada. Ainda existe a particularidade de que cada ficheiro com músicas poder conter mais do que uma música, sendo que neste caso devem ser criados 2 ficheiros latex.

4.1 Analise e Especificação

Existem várias questões que são deixadas em aberto no enunciado que irão ser especificadas nesta secção. O programa lê do stardard input e os nomes dos ficheiros latex que irão ser gerados podem ser recebidos como argumento. Caso estes não sejam especificados, assumem um título numerado, começando em 0 até à n-ésima musica interpretada. Uma vez que não se sabe a ordem pela qual os cabeçalhos se apresentam nos ficheiros a serem interpretados, o mais seguro será guardar todas as musicas em memoria e apenas imprimir para o ficheiro latex após o fim de cada música. Após a análise dos Datasets verificou-se a existência de campos no cabeçalho que não são utilizados pelo programa, devendo estes ser ignorados. Durante a análise foi também verificada a existência de anotações em algumas músicas que serviriam para apresentar as pautas, pelo que optamos por ignorar estas marcas e tentar apenas imprimir a letra da música do ficheiro latex. Existe ainda outro cuidado na criação do ficheiro latex que é apresentação na música de caracteres especiais no latex.

4.2 Implementação

4.2.1 Estrutura de dados

De forma a complementar o enunciado na secção 4.1, foi criada uma estrutura principal denominada Music, onde se guarda a informação geral da música temporariamente até esta ser imprimida para um ficheiro. Nesta estrutura ir-se-à guardar o titulo, o nome do autor e a letra da música, entre outros campos do cabeçalho que possam ser necessários.

A letra da musica é guardada numa lista ligada onde cada nodo é um linha da letra e é representada pela estrutura MusicLine. A estrutura pode ser encontrada em anexo 6.3.2.

4.2.2 Filtro de Texto

Para a filtragem do texto foram criadas várias expressões regulares, sendo que o ficheiro pode ser encontrado em anexo (6.3.1).

As primeiras expressões regulares, do tipo ^title:.+ servem para capturar os cabeçalhos que serão necessários. Existem também as expressões regulares do tipo: from, author, lyrics, music e singer, todas equivalentes. De forma a ignorar qualquer outro campo do cabeçalho que não tivesse sido previsto foi ainda criada a seguinte expressão regular: ^[a-zA-Z]+:.+.

Quanto à deteção da letra da música existem duas expressões regulares: uma para capturar uma linha da letra, outra para capturar as linhas em branco entre os poemas, que são respetivamente: $[\].*e$ n .

Tal como foi dito na análise (4.1), existem algumas anotações no meio da letra da música que são necessárias retirar. Para isso foram criadas as seguintes expressões regulares:

- {abc}(.|\n)*{abcclose} para retirar a pauta da musica.
- [].* que ignora as notas no meio dos poemas (pois estas tem um espaço no inicio).

Ainda assim estas duas expressões regulares não eram suficientes e na deteção de uma linha da letra, antes de guardar a linha, processa-se a linha com o auxílio de duas funções: takeOffAnotations e takeOffUnderSccore. A primeira retira anotações que estejam na mesma linha, e a segunda tira os caracteres ' 'que estejam no meio da linha.

4.2.3 Funcionamento

De forma a perceber melhor o funcionamento do autómato esta secção irá detalhar a ponte entre o filtro de texto (4.2.2) e a estrutura de dados (4.2.1).

À medida que o autómato captura os campos do cabeçalho da música, guarda a informação com as funções de append, p.e. appendAuthor, appendLyrics, entre outras. Estas funções guardam os campos na variável Music.

As linhas da letra são guardadas através das funções appendLine e appendWhiteLine.

Quando é detetado o início de uma nova música, através de expressão regular, é executado commitCheckNext() que escreve a letra que está atualmente na variável Music para o ficheiro latex. Caso seja detetada a falta de algum item obrigatório então a escrita para o ficheiro é cancelada. De seguida a variável Music é reiniciada para a música seguinte com a função Start().

Na escrita do ficheiro latex a letra é escrita entre as tags da latex de Verbatim para evitar erros no latex por falta de caracteres escape.

4.2.4 Testes realizados

Estão documentados neste secção 3 testes realizados ao autómato, utilizando como input os ficheiros que se encontram em anexo: 6.3.4, 6.3.4 e 6.3.4.

Teste nº 1

Após a utilização do autómato no ficheiro 6.3.4, este gerou o output (6.3.4). Este ficheiro não tem nenhuma situação excecional, é um caso normal.

Teste nº 2

Após a utilização do autómato no ficheiro 6.3.4, este gerou o output (6.3.4). Este ficheiro tem duas situações excecionais, o carácter '_ ' no meio de palavras e notas musicais no fim das frases. Podemos verificar no output que apenas tem a letra da musica.

Teste nº 3

Após a utilização do autómato no ficheiro 6.3.4, este gerou o output (6.3.4). Este ficheiro tem uma situação excecional, antes da letra da musica tem as tags <abc>...</abc> com anotações de notas musicas. Podemos verificar que no output já não está presente.

```
Um exemplo de uma possível utilização do autómato é: cat <inputFile> | ./play <output1.tex> <output2.tex> ...
```

Conclusão

Terminado o desenvolvimento do trabalho, é importante referir que o mesmo nos permitiu aprofundar o conhecimento acerca do Gerador Léxico Flex assim como da análise léxica no geral, obrigando-nos também a utilizar ferramentas tais como HTML e Latex.

Relativamente ao problema do "Museu da Pessoa", a dificuldade recaiu na definição da estrutura de suporte de dados, dado que devido à falta de claridade do enunciado foi necessário re-implementar a estrutura de forma a que esta admitisse a funcionalidade de ter um índice geral em HTML.

No problema de "Processamento de Entidades Nomeadas" foi necessário chegar a um consenso acerca das tags que deveriam ser validadas e o relacionamento possível que estas teriam entre si. Após essa decisão, o desenvolvimento da estrutura que suporta esta informação tornou-se relativamente simples.

O problema "Processamento de Ficheiros com Canções" foi resolvida através da implementação de uma estrutura capaz de evitar que a ordem dos dados no ficheiro não seja significativa (e então armazena em memória a informação). A presença de certos elementos em datasets mais diversos (tais como header's não esperados e anotações em músicas) deram origem a problemas, sendo que a solução consistiu em ignorar essa informação.

Cada elemento do grupo realizou um exercício do enunciado proposto, apoiando-se mutuamente na existência de dificuldades. Apesar das dificuldades iniciais, encontramos-nos satisfeitos com o resultado final e estamos confiantes para o próximo trabalho.

Anexos

6.1 Museu da Pessoa — tratamento de fotografias

6.1.1 Filtro de Texto

```
%{
#include "album.h"
char* token;
photo_ptr picture;
%}
%%
\footnotemark[ x_1 + [a-zA-Z] += ".*" {
yytext[strlen(yytext)-1]='\0';
picture=initPhoto(strchr(yytext,'"')+1);
setDate(picture,strchr(yytext,'"')+1);
\ensuremath{\mbox{quem>[ \t\na-zA-Z}-\ddot{A}-\hat{u},\"0-9;:]+ }
token=strchr(yytext,'>')+1;
setWho(picture,token);
\conde > [ \t n0-9a-zA-ZA-û.,;: \"]+<{
yytext[strlen(yytext)-1]='\0';
setLoc(picture,strchr(yytext,'>')+1);
$$ \color= 1.00-9a-zA-ZA-\hat{u}.,;:\"]+<{ }
yytext[strlen(yytext)-1]='\0';
setFact(picture,strchr(yytext,'>')+1);
\<\/foto>{
```

```
if(picture) {
token=strdup(picture->who);
token=strtok(token,";");
while (token){
insert_photo_person(token, picture);
token=strtok(NULL,";");
}
picture=NULL;
. | n ;
%%
6.1.2
       Estrutura de dados
\#include < stdio.h>
\#include < string.h>
\#include < stdlib.h>
#include "album.h"
static Album album;
char* trimspace(char *str)
{
          char *end;
          while (isspace (*str) | | (*str) == '\n') str++;
          if(*str == 0)
          return str;
          end = str + strlen(str) - 1;
          while (end > str && isspace (*end)) end--;
          *(\operatorname{end}+1) = 0;
          return str;
}
char* subsPoints(char *str){
          int i;
          \label{eq:formula} \textbf{for} \; (\; i = 0 \; ; \; \; i < s \, t \, r \, l \, e \, n \; (\; s \, t \, r \; ) \; ; \; i \, + +) \{
                     if (str[i]=='.')
```

str [i] = '-';

return str;

```
}
void insert_photo(photo_ptr p, photo_ptr *pics){
    if ((*pics) == NULL)
    {
         (*pics)=p;
         (*pics) -> left = NULL;
                  (*pics) -> right = NULL;
    else{}
         int comp = strcmp (p \rightarrow date, (*pics) \rightarrow date);
         if(comp < 0)
         {
                  insert photo(p, \&(*pics)->left);
         else {
                 insert_photo(p, \&(*pics)->right);
         }
    }
}
void insert photo person(char *name, photo ptr p){
    person ptr aux, newPers, lastPers;
    int done=0, comp;
    name=trimspace(name);
    if (album.people == NULL)
         album.people=malloc(sizeof(person node));
         name=trimspace (name);
         album.people->name=strdup(name);
         album.people \rightarrow href=malloc (16*sizeof (char));
         sprintf(album.people->href, "%d", album.count);
         album.people->href=strcat(album.people->href, ".html");
         album.people \rightarrow pics = p;
         album.count++;
         album.people->next=NULL;
    else{
         for (aux=album.people; aux && (comp=strcmp(aux->name, name)) < 0; aux=aux->next) {
                  lastPers=aux;
         }
         if (comp == 0)
                           insert photo(p,&aux->pics);
                  }
```

```
else {
                            newPers = malloc(sizeof(person node));
                           newPers->name=strdup(name);
                           newPers \rightarrow href = malloc(16*sizeof(char));
                            sprintf (newPers->href, "%d", album.count++);
                            newPers->href=strcat (newPers->href, ".html");
                            newPers \rightarrow pics = p;
                            if (! aux) {
                                     newPers \rightarrow next = NULL;
                                     if (lastPers) lastPers -> next=newPers;
                           }
                            else {
                                     newPers \rightarrow next = aux;
                                     if (lastPers) lastPers->next=newPers;
                                     else album.people=newPers;
                           }
                  }
         }
}
void setDate(photo ptr p, char *photoD){
         photoD=trimspace(photoD);
         photoD=subsPoints(photoD);
         p \rightarrow date = strdup (photo D);
}
void setLoc(photo_ptr p, char *photoL){
         photoL=trimspace(photoL);
         p \rightarrow loc = strdup (photoL);
}
void setFact(photo ptr p, char *photoF){
         photoF=trimspace(photoF);
         p \rightarrow fact = strdup (photoF);
}
void setWho(photo_ptr p, char *photoW){
         photoW=trimspace(photoW);
         p->who=strdup(photoW);
}
photo ptr initPhoto(char *photoN){
         photo ptr pic = malloc(sizeof(photo node));
         pic \rightarrow file = strdup (photoN);
         pic -> date=strdup ("Desconhecida");
         pic -> loc=strdup ("Desconhecido");
         pic -> fact = strdup ("Desconhecida");;
         pic -> who=strdup ("Nao_identificados");
```

```
pic \rightarrow left = NULL;
        pic \rightarrow right = NULL;
        return pic;
}
void init(){
        album.people=NULL;
        album.count = 1;
}
void appendPhoto(photo ptr p, FILE* file){
        if (p!=NULL) {
                appendPhoto(p->left, file);
                fprintf(file, "uuuu< divuclass = \"img\"uualign = \"center\">\n");
                appendPhoto(p->right, file);
        }
}
void createPage(char* filename, char* name, photo ptr p){
        FILE* file;
        photo ptr pic ptr;
        file=fopen(filename, "w+");
        fprintf(file, "<!DOCTYPE\_html>\n<|html>\n");
        fprintf(file, "<head>\n_u<meta_charset=\"UTF-8\">\n</head>\n<body>\n");
        fprintf(file, "<a_href=\"AlbumGerado.html\">Voltar</a>");
        fprintf(file, "< div_class = \"title \"_align = \"center \"> \");
        fprintf(file, "_u<h1>Album_de_fotografias</h1>\n");
        fprintf (file, "_{\sim}<h2>\%s</h2>\n</div>\n</br>\n</br>\n", name);
        fprintf(file, "< div_class = \ | gallery \ | > \ n");
         \begin{array}{l} \textbf{appendPhoto(p, file);} \\ \textbf{fprintf(file, "</div>} \\ \textbf{n</body>} \\ \textbf{n</html>");} \end{array} 
        fclose (file);
}
```

```
void createAlbum(char* filename) {
        FILE* file;
        person_ptr aux = album.people;
        file=fopen(filename, "w+");
        fprintf(file, "<!DOCTYPE\_html>\n<html>\n");
        fprintf(file, "<head>\n_u<meta_charset=\"UTF-8\">\n</head>\n<body>\n");
        fprintf(file, "<\!div\_class = \ | "title \ | "\_align = \ | "center \ | "> \ | ";
        fprintf(file, "__<h1>Album_de_fotografias</h1>\n</div>\n");
        fprintf(file, "<\!div\_class\!=\!\backslash"index\,\backslash"\!>\!\backslash n");
        fprintf(file, "u_u<div_uclass=\\"indextitle/"u_ualign=\\"center/">\\n");
        while (aux) {
        fprintf(file, "uuuuu<a_bhref=\\"%s\">%s</a><href, aux->href, aux->name);
        createPage(aux->href, aux->name, aux->pics);
        aux=aux->next;
    }
        fprintf(file, "uuuu
    /ul>
    /ul> \nuu
        fprintf(file, "</body>\n</html>");
        fclose (file);
}
int main(int argc, char* argv[]){
        init();
        yylex();
        if(argc == 2){
                 createAlbum (argv[1]);
        else {
                createAlbum("AlbumGerado.html");
        return 0;
}
       Cabeçalho ficheiro C
\#ifndef __album h
```

```
\#define __album_h__
typedef struct sPhoto *photo ptr;
typedef struct sPhoto {
        char* file;
        char* date;
        char* loc;
        char* fact;
        char* who;
        photo ptr left;
        photo_ptr right;
} photo node;
typedef struct person *person_ptr;
typedef struct person
    char* name;
    char* href;
    photo ptr pics;
    person_ptr next;
} person_node;
typedef struct sAlbum {
        person_ptr people;
        int count;
} Album;
void setDate(photo_ptr p, char *photoD);
void setLoc(photo ptr p, char *photoL);
void setFact(photo ptr p, char *photoF);
void setWho(photo_ptr p, char *photoW);
photo ptr initPhoto(char *photoN);
void insert_photo_person(char *name, photo_ptr p);
#endif
```

6.2 Processamento de Entidades Nomeadas (Enamex)

6.2.1 Filtro de Texto

```
%s country
%{
    #include "tree.h"
```

```
char *aux;
    char* aux_subcity;
    int aux_len;
   tree_ptr persons=NULL;
   tree_ptr countrys = NULL;
    tree_ptr citys = NULL;
    tree_ptr organizations = NULL;
    tree_ptr otherlocations = NULL;
    char* trimspace(char *str);
%}
            [a-zA-ZO-9\zeta-\widetilde{N}A-\widehat{u}]+
pal
            \<[ \t]*(?i:enamex)[ \t]+(?i:type)=
enamex
            \c \t := mamex)[ \t] *\
eclose
            \"[ \t]*(?i:organization)[ \t]*\"[ \t]*\>
org
           \"[ \t]*(?i:person)[ \t]*\"[ \t]*\>
person
loc
            "[ \t]*(?i:location)[ \t]*"[ \t]*()?
(?i:subtype) = \"[ \t] * (?i:city) [ \t] * \"[ \t] * \
subcity
%%
   BEGIN O;
{enamex}{loc}{subcountry}{pal}{eclose}
        aux=strdup(strchr(yytext,'>')+1);
        *strchr(aux,'<')='\0';
        insert(trimspace(aux), &countrys);
        BEGIN country;
   }
<country>\.
                                BEGIN O;
<country>{enamex}{loc}{subcity}{pal}{eclose}
        tree_ptr aux_tree = search_tree(aux, countrys);
        aux_subcity=strdup(strchr(yytext,'>')+1);
        *strchr(aux_subcity,'<')='\0';
        insert_subtree(trimspace(aux_subcity), &countrys);
        insert(trimspace(aux_subcity), &citys);
       BEGIN O;
{enamex}{person}{pal}{eclose}
        aux=strdup(strchr(yytext,'>')+1);
        *strchr(aux,'<')='\0';
        insert(trimspace(aux), &persons);
{enamex}{org}{pal}{eclose} {
        aux=strdup(strchr(yytext,'>')+1);
        *strchr(aux,'<')='\0';
```

```
insert(trimspace(aux), &organizations);
{enamex}{loc}{subcity}{pal}{eclose} {
      aux=strdup(strchr(yytext,'>')+1);
      *strchr(aux,'<')='\0';
      insert(trimspace(aux), &citys);
  }
{enamex}{loc}{pal}{eclose} {
       aux=strdup(strchr(yytext,'>')+1);
       *strchr(aux,'<')='\0';
       insert(trimspace(aux), &otherlocations);
   }
<*>.|\n
                         ;
%%
/*Função que retira os espaços brancos dos nomes*/
char* trimspace(char *str)
{
   char *end;
   while(isspace(*str)) str++;
   if(*str == 0)
       return str;
   end = str + strlen(str) - 1;
   while(end > str && isspace(*end)) end--;
   *(end+1) = 0;
   return str;
}
void printHeader(FILE *f){
   fprintf(f, "<DOCTYPE !html>\n<html>\n\t<head> <meta charset=\"UTF-8\">\n Grupo 7</head>\n");
   fprintf(f, "< link type= \"text/css \" rel= \"style sheet \" href= \"style sheet.css \"/>");
   fprintf(f, "\t<title>Processamento de Linguagens</title><body>");
}
void createIndex(FILE *f){
   printHeader(f);
   fprintf(f, "<h1>Processamento de Linguagens</h1></a>\n");
   fprintf(f, "<a href=\persons.html\">Persons</a>\n");
   fprintf(f, "<a href=\"countrys.html\">Countrys</a>\n");
```

```
fprintf(f, "<a href=\"organizations.html\">Organizations</a>\n");
   fprintf(f, "<a href=\"citys.html\">City's</a>\n");
   fprintf(f, "<a href=\"otherlocations.html\">Other Locations</a>\n");
   fprintf(f, "\t</body>\n</html>\n");
}
int yywrap()
{ return(1); }
int main()
   yylex();
   FILE *i, *p, *c, *o, *ac, *ol;
   i = fopen("web/index.html", "w");
   createIndex(i);
   fclose(i);
   p = fopen("web/persons.html", "w");
   printHeader(p);
   fprintf(p, "<h1>Persons</h1>");
   treeToHtml(persons,p);
   fprintf(p, "<a href=\"index.html\">Voltar</a>\n\t</body>\n</html>\n");
   fclose(p);
   c = fopen("web/countrys.html", "w");
   printHeader(c);
   fprintf(c, "<h1>Countrys</h1>");
   treeToHtml(countrys,c);
   fprintf(c, "<a href=\"index.html\">Voltar</a>\n\t</body>\n</html>\n");
   fclose(c);
   o = fopen("web/organizations.html", "w");
   printHeader(o);
   fprintf(o, "<h1>Organizations</h1>");
   treeToHtml(organizations,o);
   fprintf(o, "<a href=\"index.html\">Voltar</a>\n\t</body>\n</html>\n");
   fclose(o);
   ac = fopen("web/citys.html", "w");
   printHeader(ac);
   fprintf(ac, "<h1>City's</h1>");
   treeToHtml(citys,ac);
   fprintf(ac, "<a href=\\"index.html\\">Voltar</a>\\n\t</body>\\n</html>\\n");
   fclose(ac);
   ol = fopen("web/otherlocations.html", "w");
   printHeader(ol);
```

```
fprintf(ol, "<h1>Other Locations</h1>");
    treeToHtml(otherlocations,ol);
    fprintf(ol, "<a href=\"index.html\">Voltar</a>\n\t</body>\n</html>\n");
    fclose(ol);
    return 0;
}
6.2.2
       Estrutura de dados
#include < stdlib . h>
#include < stdio.h>
\#include < string.h>
#include "tree.h"
typedef struct tree
    char desig[MAX SIZE];
    int num;
    tree_ptr left , right , subtree;
} Tree;
void insert(char *novo_desig, tree_ptr *p)
{
    if ((*p) == NULL)
    {
         (*p) = (tree_ptr) malloc(sizeof(Tree));
         strcpy((*p)->desig,novo_desig);
         (*p)->num=1;
         (*p)-> left=NULL;
         (*p) -> r i g h t = NULL;
         (*p) -> subtree = NULL;
    }
    else {
         int comp=strcmp(novo_desig,(*p)->desig);
         if(comp < 0)
             insert (novo desig, \&(*p)->left);
         else if (comp > 0)
             {
                  insert (novo\_desig, \&(*p)-> right);
             }
```

```
else
                         ->num++;
          }
}
void insert_subtree(char *novo_desig, tree_ptr *p){
     if ((*p) != NULL)
     {
          insert (novo desig, &(*p)->subtree);
     }
}
void subtree_to_html(tree_ptr sub_arv, FILE *f){
     if (sub_arv != NULL) {
          subtree_to_html(sub_arv->left , f);
          fprintf (f, "");
          subtree to html(sub arv->right, f);
     }
}
void treeToHtml(tree ptr btree, FILE *f){
     if (btree != NULL)
     {
           \label{eq:treeToHtml} $$\operatorname{treeToHtml}(btree \to left\ ,\ f);$$ fprintf(f, "<p_class=\"root\">\%s\n", btree \to desig);
          if (btree->subtree != NULL)
               subtree to html(btree->subtree, f);
          treeToHtml(btree->right, f);
     }
}
void imprime_inorder_tree(tree_ptr p)
     if (p!=NULL)
          imprime inorder tree (p->left);
          \label{eq:continuity} p\, r\, \bar{i}\, n\, t\, f\, \left(\, \overline{\text{"\%}} s\, \_-\!\!>\! \_\% d\, \backslash\, n\, \text{"}\, , p-\!\!>\! d\, e\, s\, i\, g\, \,, \quad p-\!\!>\! num\, \right);
          if (p->subtree != NULL) imprime_inorder_tree(p->subtree);
          imprime_inorder_tree(p->right);
     }
}
```

```
tree ptr copyTree (tree ptr p)
    {\tt tree\_ptr~aux}\!\!=\!\!\!NULL;
    if (p!=NULL) {
        insert (p->desig,&aux);
        aux \rightarrow left = copyTree(p \rightarrow left);
        aux -> right = copyTree(p -> right);
    return aux;
}
void imprime mais freq(tree ptr p, int n)
    if (p!=NULL)
    {
        imprime_mais_freq(p->left,n);
        if ((p->num)>n) printf("%s\n",p->desig);
        imprime_mais_freq(p->right,n);
    }
}
int total Pubs(tree ptr p)
    if (!p) return 0;
    else return (p->num)+total_Pubs(p->left)+total_Pubs(p->right);
}
int total elems(tree ptr p) {
    if (!p) return 0;
    else return 1 + total elems (p->left)+total elems (p->right);
}
tree_ptr search_tree(char *desig, tree_ptr p)
{
    if (!p) return NULL;
    else {
        int comp=strcmp(p->desig,desig);
        if (comp==0) return (p);
        else {
             if (comp>0) return search_tree(desig, p->left);
             else return search_tree(desig, p->right);
        }
    }
}
```

```
void imprime pos order by N(tree ptr p, int *N) {
    if (p) {
        imprime_pos_order_by_N(p->right,N);
        if (*N) {
             printf("Elemento: \ \ \ \ \ \ \ \ \ \ \ \ \ p->desig);
             printf("Nmr: \sqrt{d} / n / n", p->num);
             (*N) - -;
        imprime pos order by N(p->left,N);
    }
}
void makeempty(tree ptr p)
    if (p != NULL)
        makeempty (p->left);
        makeempty (p->right);
        free (p);
    }
}
       Cabeçalho ficheiro C
6.2.3
\#ifndef ____TREE_H___
#define TREE H
#define MAX SIZE 200
typedef struct tree *tree ptr;
/*Insere um novo elemento na BS-tree*/
void insert(char *novo_desig, tree_ptr *p);
/*Imprime\ todos\ os\ nodos(elementos)\ da\ BS-tree\ por\ orden\ alfabetica*/
void imprime inorder tree(tree ptr p);
/*Imprime os elementos que aparecem no minimo n vezes*/
void imprime mais freq(tree ptr p, int n);
/*Devolve numero de ocorrencias de todos os elementos da BS-tree*/
int total_Pubs(tree_ptr p);
/*Devolve numero de nodos (elementos) da BS-tree*/
int total_elems(tree_ptr p);
```

```
/*Copia uma BS-tree*/
tree_ptr copyTree (tree_ptr p);

/*Procura um elemento numa BS-tree e devolve um apontador ele caso se encontrar.*/
tree_ptr search_tree(char *desig, tree_ptr p);

/*Imprime por ordem decrescente de numero de ocorrencias.*/
void imprime_pos_order_by_N(tree_ptr p, int *N);

/*Liberta memoria de BS-tree*/
void makeempty(tree_ptr p);

/*Insere elementos em subarvore*/
void insert_subtree(char *novo_desig, tree_ptr *p);

/*Imprime para ficheiro uma dada subarvore*/
void treeToHtml(tree_ptr btree, FILE *f);

void subtree_to_html(tree_ptr sub_arv, FILE *f);

#endif
```

6.2.4 Testes

Input teste 1

O meu nome é <ENAMEX TYPE="PERSON">Paulo úArajo</ENAMEX> e sou de < ENAMEX TYPE="LOCATION" SUBTYPE="COUNTRY">Portugal</ENAMEX>, que tem cidades ãto bonitas como <ENAMEX TYPE="LOCATION" SUBTYPE="CITY">Braga</ENAMEX>, <ENAMEX TYPE="LOCATION" SUBTYPE="CITY">Viana do Castelo</ENAMEX> e <ENAMEX TYPE="LOCATION" SUBTYPE="CITY">Lisboa</ENAMEX>. ãNo tem cidades menos bonitas como <ENAMEX TYPE="LOCATION" SUBTYPE="LOCATION" SUBTYPE="LOCATION" SUBTYPE="CITY">Texas</ENAMEX> e <ENAMEX TYPE="LOCATION" SUBTYPE="CITY">Novo Mexico</ENAMEX>.

Output teste 1

Grupo 7

Portugal

- Braga
- Lisboa
- Viana do Castelo

Voltar

Input teste 2

<ENAMEX TYPE="PERSON"> Bento de Castro Abreu </ENAMEX>, que emigrou
para o <ENAMEX TYPE="LOCATION" SUBTYPE="CITY"> Rio de Janeiro </
ENAMEX> em <TIMEX TYPE="DATE"> 1/2/1895 </TIMEX>, com 26 anos de
idade, é referido no seu passaporte como áproprietrio, sobrinho de
outro <ENAMEX TYPE="?"> Brasileiro </ENAMEX> <ENAMEX TYPE="
PERSON"> Fernando de Castro Abreu e ãMagalhes </ENAMEX>, que
apoiou financeiramente a çãconstruo da casa do <ENAMEX TYPE="
LOCATION"> Santo Novo </ENAMEX>.

<ENAMEX TYPE="?">Foi Visconde e êMarqus de àParanagu</ENAMEX> <ENAMEX
 TYPE="PERSON">Francisco Vilela Barbosa</ENAMEX> que nasceu no <
 ENAMEX TYPE="LOCATION" SUBTYPE="COUNTRY">Brasil</ENAMEX> , em <
 ENAMEX TYPE="LOCATION" SUBTYPE="CITY">Parati</ENAMEX> em <ENAMEX
 TYPE="?">Novembro</ENAMEX> de <NUMEX>1769</NUMEX> e ali morreu em <TIMEX TYPE="DATE">Setembro de 1846</TIMEX> , filho de <ENAMEX TYPE = "PERSON">Francisco Vilela Barbosa</ENAMEX> , natural de <ENAMEX
 TYPE="LOCATION" SUBTYPE="CITY">Braga</ENAMEX> (<ENAMEX TYPE="LOCATION" SUBTYPE="COUNTRY">PORTUGAI</ENAMEX>) e de <ENAMEX TYPE="PERSON">D. Ana Maria da çãConceio</ENAMEX> .

Formado em ámatemtica pela <ENAMEX TYPE="ORGANIZATION"> Universidade de Coimbra</ENAMEX>, em <Numex>1789</NuMEX> assentou çpraa na armada e quando °2 tenente prestou relevantes çservios no cerco de <ENAMEX TYPE="LOCATION" SUBTYPE="CITY"> Tunis</ENAMEX> e na çãperseguio aos pirata argelinos do <ENAMEX TYPE="?"> âMediterrneo</ENAMEX>.

Nomeado lente da <FNAMEX TYPE="ORGANIZATION">Academia da Marinha</FNAMEX>, passou em <Numex>1801</NuMEX> para o <FNAMEX TYPE="ORGANIZATION">Real Corpo de Engenheiros</FNAMEX> e em <Numex>1810</f>
/NuMEX> foi promovido a <FNAMEX TYPE="?">Major</FNAMEX> e reformado mais tarde no posto de <FNAMEX TYPE="?">Brigadeiro</FNAMEX> e Enamex>.

Output teste 2



Input teste 3

```
</PREAMBLE>
<TEXT>
A Chinese rocket carrying a television satellite exploded
seconds after launch <TIMEX TYPE="DATE">Wednesday</TIMEX>, dealing a
   potential blow to <ENAMEX TYPE="PERSON">Rupert
Murdoch < /ENAMEX>'s ambitions to offer satellite programming in <
   ENAMEX\_TYPE="LOCATION">Latin
America < /ENAMEX>.
<ENAMEX_TYPE="PERSON">Murdoch</ENAMEX>'s <ENAMEX TYPE="ORGANIZATION">
   News Corp. < /ENAMEX> is one of four media companies in a
partnership that had leased space on the <ENAMEX TYPE="ORGANIZATION">
    Intelsat</ENAMEX> satellite to
offer the Latin American service. The other partners are
<ENAMEX TYPE="ORGANIZATION">Tele-Communications Inc.</ENAMEX>, the
   nation's_largest_cable_operator;
<ENAMEX_TYPE="ORGANIZATION">Grupo_Televisa_SA</ENAMEX>,_the_Mexican_
   broadcaster_and_publisher,_and_the
giant_Brazilian_media_conglomerate_<ENAMEX_TYPE="ORGANIZATION">Globo
   </ENAMEX>.
>
<ENAMEX_TYPE="PERSON">Llennel_Evangelista</ENAMEX>,_a_spokesman_for_<
   ENAMEX_TYPE="ORGANIZATION"> Intelsat </ENAMEX>, _a _ global
satellite_consortium_based_in_<ENAMEX_TYPE="LOCATION"> Washington </
   ENAMEX>, said the accident
occurred_at_<TIMEX_TYPE="TIME">2_p.m._EST</TIMEX>_<TIMEX_TYPE="DATE">
   Wednesday</TIMEX>, _ or _<TIMEX_TYPE="TIME"> early _ Thursday _ morning</
   TIMEX>_at_the
<ENAMEX_TYPE="LOCATION"> Xichang</ENAMEX>_ launch_site_in_<ENAMEX_TYPE
   ="LOCATION">Sichuan_Province</ENAMEX>_in_southwestern_<ENAMEX_TYPE
   ="LOCATION">China</ENAMEX>...' 'We
have_no_details_on_what_caused_the_accident, ''_he_said.
<ENAMEX_TYPE="PERSON"> Evangelista</ENAMEX>_said_the_Chinese-built_
   Long_March_rocket_veered_off
course_and_was_destroyed_after_it_failed_to_reach_orbit._<ENAMEX_TYPE
   ="ORGANIZATION"> Intelsat </ENAMEX>
was\_using\_the\_Long\_March\_rocket\_for\_the\_first\_time\_to\_launch\_one\_of
its\_satellites.\_<\!ENAMEX\_TYPE="ORGANIZATION">Intelsat</\!ENAMEX>\_
   currently_has_23_satellites_in_orbit.
A_spokesman_for_<ENAMEX_TYPE="ORGANIZATION">News_Corp.</ENAMEX>,<
   ENAMEX_TYPE="PERSON"> Howard_Rubenstein</ENAMEX>,_said_the_accident
would_not_hinder_the_group's plans to offer 150 channels of
entertainment, news and sports programming to viewers in <ENAMEX TYPE
   ="LOCATION">Latin
America < /ENAMEX > and the <ENAMEX TYPE="LOCATION" > Caribbean < /ENAMEX > .
```

```
other real options and will
disclose them shortly, '' <ENAMEX TYPE="PERSON">Rubinstein</ENAMEX>
   said in a statement.
<ENAMEX TYPE="ORGANIZATION">Grupo Televisa</ENAMEX> and <ENAMEX TYPE=
   "ORGANIZATION">Globo</ENAMEX> plan to offer national and local
programming in Spanish and Portuguese. Initially, the venture's
partners_said_they_planned_to_invest_<\UMEX_TYPE="MONEY">\$500_million
   < /NUMEX>.
>
But_a_similar_explosion_<TIMEX_TYPE="DATE">last_year</TIMEX>_delayed_
   the_plans_of_several
American\_media\_companies\_to\_offer\_a\_package\_of\_satellite\_television
ORGANIZATION">Viacom</ENAMEX>, \_<ENAMEX\_TYPE="ORGANIZATION">Time\_
   Warner</ENAMEX>'s <ENAMEX TYPE="ORGANIZATION">Home Box Office</
   ENAMEX and <ENAMEX TYPE="ORGANIZATION">Turner
Broadcasting System < /ENAMEX> were among the companies that had leased
on an Apstar 2 satellite to beam MTV, CNN and other channels
throughout <ENAMEX TYPE="LOCATION">Asia</ENAMEX>.
After the rocket carrying that satellite exploded, media
analysts said the companies had to settle for space on a series of
regional satellites, which had less reach than the Apstar 2 would
have offered.
<\!\!E\!N\!A\!M\!E\!X\ TYPE\!\!=\!"ORGANIZATION">\!\!News\ Corp.<\!\!/E\!N\!A\!M\!E\!X\!\!>\ actually\ benefited
   from that accident. In <TIMEX TYPE="DATE">1993</TIMEX>, the
company had purchased a controlling stake in a rival Asian
ENAMEX>. With his biggest competitors unable to
enter the Asian market, <ENAMEX TYPE="PERSON">Murdoch</ENAMEX> was
   able to build <ENAMEX TYPE="ORGANIZATION" STATUS="OPT">Star TV</
   ENAMEX> into the
dominant programming service.
A spokeswoman for <ENAMEX TYPE="ORGANIZATION">Tele-Communications</
   ENAMEX>, <ENAMEX TYPE="PERSON">LaRae Marsik</ENAMEX>, said the
partners in the Latin American venture intended to begin service by
<TIMEX TYPE="DATE">the end of 1996</TIMEX>. When the companies
   announced their plans <TIMEX TYPE="DATE">last
November < / TIMEX >, they said they planned to be in business by < TIMEX
   TYPE="DATE">May</TIMEX>.
>
Ms. <ENAMEX TYPE="PERSON">Marsik</ENAMEX> said <ENAMEX TYPE="
   ORGANIZATION">Tele-Communications</ENAMEX> and its partners had a
back-up plan, which could include leasing space on another
```

''<ENAMEX TYPE="ORGANIZATION">News Corp.</ENAMEX> has a number of

```
satellite, but she declined to offer details. "It is an
unfortunate incident, '' she said, ''but it is not a
make-it-or-break-it event for us. ''
<ENAMEX TYPE="PERSON">Jessica Reif</ENAMEX>, a media analyst at <
   ENAMEX TYPE="ORGANIZATION"> Merrill Lynch & Co.</ENAMEX>, said, ''
they can get up and running with exclusive programming <TIMEX TYPE="
   DATE" STATUS="OPT"> within six
months</TIMEX>, it doesn't_set_the_venture_back_that_far.''
<\!\!ENAMEX\_TYPE\!\!=\!"ORGANIZATION">\!\!Hughes\_Electronics<\!\!/ENAMEX>\!\!,\_a\_subsidiary
   \_ of \_ the \_ <ENAMEX\_TYPE="ORGANIZATION"> General \_ Motors \_ Corp. < /ENAMEX>,
starting_its_own_satellite_broadcast_service_in_<ENAMEX_TYPE="
   LOCATION" > Latin \_America < /ENAMEX>. \_Ms.
<\!\!E\!N\!A\!M\!E\!X\!\!\_T\!Y\!P\!E\!\!=\!"\!P\!E\!R\!S\!O\!N"\!\!>\!Reif\!<\!\!/\!E\!N\!A\!M\!E\!X\!\!>\!\!\_said\_that\_venture\;, \_which\_is\_based
   _on_<ENAMEX_TYPE="ORGANIZATION">Hughes</ENAMEX>'s <ENAMEX TYPE="
   ORGANIZATION" STATUS="OPT">DirecTV</ENAMEX> service
in the <ENAMEX TYPE="LOCATION"> United States < /ENAMEX>, would benefit
    if the explosion delayed the
<ENAMEX TYPE="PERSON">Murdoch</ENAMEX>-led venture.
</TEXT>
<TRAILER>
TIMEX>
</TRAILER>
</DOC>
```

Grupo 7

Globo

Grupo Televisa

Grupo Televisa SA

Home Box Office

Hughes

Hughes Electronics

Intelsat

Time Warner

Viacom

<u>Voltar</u>

6.3 Processamento de ficheiros com Canções

6.3.1 Filtro de Texto

```
%{
#include "musica.h"

char* takeOffAnotations(char* c){
   int i=0;
   while(c[i] != '\0' && !(c[i] == ' ' && c[i + 1] == ' ')) {
        i++;
   }
   c[i] = '\0';
   return c;
}
```

```
char* takeOffUnderSccore(char* c){
   int i=0, w=0;
   while(c[i] != '\0') {
        //ignore if '_'
        if(c[i] != '_') {
            c[w] = c[i];
            w++;
        }
        i++;
   }
   c[w] = ',0';
   return c;
}
%}
        \<[ ]*(?i:abc)[ ]*\>
abcclose
             \<\/[]*(?i:abc)[]*\>
%%
^title:.+
                appendTitle(yytext + 6);
^from:.+
                appendFrom(yytext + 5);
^author:.+
                appendAuthor(yytext + 7);
                appendLyrics(yytext + 7);
^lyrics:.+
^music:.+
                appendMusic(yytext + 6);
^singer:.+
                appendSinger(yytext + 7);
^[a-zA-Z]+:.+
                ;// Ignore other headers:
\{abc\}(.|\n)*\{abcclose\};
##-+
        {commitCheckNext(); start();}// Music End
^\n
        appendWhiteLine(); // white music line.
[].*
        ; //ignore lines that start with space (they are music anotations);
        {appendLine(takeOffAnotations(takeOffUnderSccore(yytext)));
        //poem line, taking of underscore and music annotations}
. | \n
%%
6.3.2
       Estrutura de dados
```

```
#include <stdio.h>
#include <unistd.h>
#include "musica.h"
#include <stdlib.h>
```

```
\#include < string.h>
 private header area
extern int yylex();
typedef struct sMusicLine {
   char* line;
   struct sMusicLine* next;
} MusicLine;
typedef struct sMusic {
  char* _Title;
   char* _From;
   char* _Author;
   char* _ Lyrics;
  char* _Music;
  char* Singer;
   MusicLine* poem;
   MusicLine* poemEnd;
   int error;
} Music;
void writeLatex();
Implementation Area
static Music music;
static char** argv;
static int argc;
static int argIndex;
#define append (name) \
   void append##name(char* t) { \
     if (music. ##name != NULL) { \
        music.error = 1;
     } else \{ \ \ \ \ \ \ \ \}
        music._##name = strdup(t); \
   } \
append (Title)
append (From)
```

```
append (Author)
append (Lyrics)
append (Music)
append (Singer)
void appendLine(char* line) {
    if (music.poemEnd == NULL){
        music.poem = (MusicLine*) malloc(sizeof(MusicLine));
        music.poemEnd = music.poem;
        music.poemEnd->next = (MusicLine*) malloc(sizeof(MusicLine));
        music.poemEnd = music.poemEnd->next;
    music.poemEnd->next = NULL;
    music.poemEnd->line = strdup(line);
}
void appendWhiteLine() {
    // don't append white line in the init of the file
    if (music poemEnd != NULL) {
        music.poemEnd->next = (MusicLine*) malloc(sizeof(MusicLine));
        music.poemEnd = music.poemEnd->next;
        music.poemEnd->next = NULL;
        music.poemEnd \rightarrow line = strdup("");
    }
}
void start() {
    music.\_Title\ =\ NULL;
    music._From = NULL;
    music. Author = NULL;
    music._Lyrics = NULL;
    music._Music = NULL;
    music._Singer = NULL;
    music.poem = NULL;
    music.poemEnd = NULL;
    music.error = 0;
}
void writeLatex(Music m, FILE* f) {
    fprintf(f, "\\title{%s}\n",m. Title);
    if (m. Author != NULL) {
        fprintf(f, "\\ \Delta uthor{%s}\n", m. _Author);
    } else {}
        fprintf(f, "\\ \\ \\ author\{\%s,\%s\}\\ \\ n",m.\_Lyrics,m.\_Music);
```

```
fprintf(f, " \setminus document class[12 pt]{article} \setminus n");
     fprintf(f, "\\begin{document}\n");
     fprintf(f, " \setminus maketitle \setminus n");
     fprintf(f, " \setminus section * \{Letra\} \setminus n");
     fprintf(f, " \setminus begin\{center\} \setminus n");
     MusicLine* it;
     fprintf(f, " \setminus \setminus begin\{verbatim\} \setminus n");\\
     for (it = m.poem; it ; it = it -> next)
         // insert line
         //if (it -> line[0] != '\0') 
         fprintf(f, "%s \ n", it \rightarrow line);
         //} else {
              // insert white space
              //fprintf(f, "| vspace {5mm}| n");
         //}
     fprintf(f, " \setminus end\{verbatim\} \setminus n");
     if (m._Singer){
         fprint\bar{f}(f,"' \setminus vspace{5mm} \setminus n");
         fprintf(f, "\\ hfill \%s\n",m. Singer);
     fprintf(f, "\setminus end\{center\}\setminus n");
     fprintf(f,"\\end{document}\n");
}
int commitCheckNext() {
     if (music.error!= 0) {
          // need something here?
     } else {
         FILE* f;
         if (argIndex < argc) 
              f = fopen(argv[argIndex], "w");
               writeLatex (music, f);
               fflush(f);
               fclose(f);
                 execl("/usr/bin/pdflatex", "pdflatex", argv[argIndex], NULL);
         } else {
              char buffer [20];
               sprintf (buffer, "%d.tex", argIndex);
               f = fopen(buffer, "w");
               writeLatex (music, f);
               fflush(f);
               fclose(f);
                 execl("/usr/bin/pdflatex", "pdflatex", buffer, NULL);
         }
         argIndex++;
    }
```

```
return music.error;
}
\begin{array}{lll} \textbf{int} & \min\left(\textbf{int} & \_\operatorname{argc}\,, & \textbf{char}* & \_\operatorname{argv}\left[\,\right]\,\right) \, \{ \\ & \operatorname{argc} & = & \_\operatorname{argc}\,-1 \; ; \; // \; \textit{first argument is the program name} \,. \end{array}
      argv = (char**) malloc(sizeof(char) * _argc);
      for(_argc--;_argc>0;_argc--){
           argv[argc - 1] = strdup(argv[argc]);
      start();
      yylex();
     commitCheckNext();
}
int yywrap() {
     return -1;
}
6.3.3
         Cabeçalho ficheiro C
#ifndef __musica_h__
#define __musica_h__
void appendTitle(char* title);
void appendFrom(char* from);
void appendAuthor(char* author);
void appendLine(char* line);
void appendWhiteLine();
void start();
int commitCheckNext();
#endif
6.3.4
         Testes
Input teste 1
title: Amêndoa Amarga
lyrics: José Carlos Ary dos Santos
music: Alain Oulman
singer: Amália Rodrigues
Port ti falo
e ninguém pensa
mas eu digo
```

minha amêndoa, meu amigo meu irmão meu tropel de ternura minha casa meu jardim de carência minha asa.

Por ti vivo
e ninguém pensa
mas eu sigo
um caminho de silvas
e de nardos
uma intensa ternura
que persigo
rodeada de cardos
por tantos lados.

Por ti morro
e ninguém sabe
mas eu espero
o teu corpo que sabe
a madrugada
o teu corpo que sabe
a desespero

ó minha amarga amêndoa desejada.

ó minha amarga amêndoa desejada.

Output teste 1

\title{ Amêndoa Amarga}
\author{ José Carlos Ary dos Santos, Alain Oulman }
\documentclass[12pt]{article}
\begin{document}
\maketitle
\section*{Letra}
\begin{center}
\begin{verbatim}
Port ti falo
e ninguém pensa
mas eu digo
minha amêndoa, meu amigo
meu irmão
meu tropel de ternura
minha casa

meu jardim de carência minha asa.

Por ti vivo
e ninguém pensa
mas eu sigo
um caminho de silvas
e de nardos
uma intensa ternura
que persigo
rodeada de cardos
por tantos lados.

Por ti morro
e ninguém sabe
mas eu espero
o teu corpo que sabe
a madrugada
o teu corpo que sabe
a desespero

ó minha amarga amêndoa desejada.

ó minha amarga amêndoa
desejada.
\end{verbatim}
\vspace{5mm}
\hfill Amália Rodrigues
\end{center}
\end{document}

Input teste 2

title: Amêndoa Amarga

lyrics: José Carlos Ary dos Santos

music: Alain Oulman singer: Amália Rodrigues

Port ti falo
e ninguém pensa
mas eu digo
minha amêndoa, meu amigo
meu irmão
meu tropel de ternura
minha casa
meu jardim de carência
minha asa.

Por ti vivo
e ninguém pensa
mas eu sigo
um caminho de silvas
e de nardos
uma intensa ternura
que persigo
rodeada de cardos
por tantos lados.

Por ti morro
e ninguém sabe
mas eu espero
o teu corpo que sabe
a madrugada
o teu corpo que sabe
a desespero

ó minha amarga amêndoa desejada.

ó minha amarga amêndoa desejada.

Output teste 2

\title{ * Tejo que levas as águas}
\author{ Manuel da Fonseca, Adriano Correia de Oliveira}
\documentclass[12pt]{article}
\begin{document}
\maketitle
\section*{Letra}
\begin{center}
\begin{verbatim}
Tejo que levas as águas
correndo de par em par
lava a cidade de mágoas
leva as mágoas para o mar

Lava-a de crimes espantos de roubos, fomes, terrores, lava a cidade de quantos do ódio fingem amores

Leva nas águas as grades de aço e silêncio forjadas deixa soltar-se a verdade das bocas amordaçadas

Lava bancos e empresas dos comedores de dinheiro que dos salários de tristeza arrecadam lucro inteiro

Lava palácios vivendas casebres bairros da lata leva negócios e rendas que a uns farta e a outros mata

Tejo que levas as águas correndo de par em par lava a cidade de mágoas leva as mágoas para o mar

Lava avenidas de vícios vielas de amores venais lava albergues e hospícios cadeias e hospitais

Afoga empenhos favores vãs glórias, ocas palmas leva o poder dos senhores que compram corpos e almas

Leva nas águas as grades

Das camas de amor comprado desata abraços de lodo rostos corpos destroçados lava-os com sal e iodo

Tejo que levas nas águas
...
\end{verbatim}
\vspace{5mm}
\hfill Adriano Correia de Oliveira
\end{center}
\end{document}

Input teste 3

title: = Raúl tinha um Ioio singer: Bando dos Gambozinos lyrics: Manuel António Pina

```
music: Suzana Ralha
in: "o beco dos gambozinos"
from: jj
<abc>
X: 1
M: 2/4
K: C
Q: 1/4=60
L: 1/8
dc Ad | dc Ad | dc Ad | GG AA |
w:Ra-ul ti-nhaum i-oi-o que io-io-ia-va to-do o di-a
z/2 D/2E/2F/2 G>G | AG F2 |1 z/2 D/2E/2F/2 G>G | AG F2 :|2 z F/2A/2 GG | FE DD |]
w:quan-doo Ra-úl fa-zia ó-ó o i-o-io a-dor-me-cia
</abc>
Raúl tinha um ioio
que ioioiava todo o dia
quando o Raúl fazia ó-ó
o ioio adormecia
E quando o Raúl chorava
porque o ó-ó não vinha
o ioio embalava
para baixo e para cima
Raúl dormia e sonhava
e quando sonhava sorria
porque o io-io ioioiava
nos sonhos que Raúl via
Output teste 3
\title{ = Raul tinha um Ioio}
\author{ Manuel António Pina, Suzana Ralha}
\documentclass[12pt]{article}
\begin{document}
\maketitle
```

\section*{Letra}
\begin{center}
\begin{verbatim}
Raúl tinha um ioio
que ioioiava todo o dia
quando o Raúl fazia ó-ó

o ioio adormecia

E quando o Raúl chorava porque o ó-ó não vinha o ioio embalava para baixo e para cima

Raúl dormia e sonhava
e quando sonhava sorria
porque o io-io ioioiava
nos sonhos que Raúl via
\end{verbatim}
\vspace{5mm}
\hfill Bando dos Gambozinos
\end{center}
\end{document}

Amndoa Amarga

Jos Carlos Ary dos Santos, Alain Oulman ${\it April~1,~2015}$

Letra

Port ti falo
e ningum pensa
mas eu digo
minha amndoa, meu amigo
meu irmo
meu tropel de ternura
minha casa
meu jardim de carncia
minha asa.

Por ti vivo
e ningum pensa
mas eu sigo
um caminho de silvas
e de nardos
uma intensa ternura
que persigo
rodeada de cardos
por tantos lados.

Por ti morro
e ningum sabe
mas eu espero
o teu corpo que sabe
a madrugada

1

Figura 6.1: PDF gerado por o ficheiro latex (teste 1). Pagina 1 de 2

Por ti morro
e ningum sabe
mas eu espero
o teu corpo que sabe
a madrugada

1

o teu corpo que sabe a desespero

minha amarga amndoa desejada.

minha amarga amndoa desejada.

Amlia Rodrigues

Figura 6.2: PDF gerado por o ficheiro latex (teste 1). Pagina 2 de 2

* Tejo que levas as guas

Manuel da Fonseca, Adriano Correia de Oliveira April 1, 2015

Letra

Tejo que levas as guas correndo de par em par lava a cidade de mgoas leva as mgoas para o mar

Lava-a de crimes espantos de roubos, fomes, terrores, lava a cidade de quantos do dio fingem amores

Leva nas guas as grades de ao e silncio forjadas deixa soltar-se a verdade das bocas amordaadas

Lava bancos e empresas dos comedores de dinheiro que dos salrios de tristeza arrecadam lucro inteiro

Lava palcios vivendas casebres bairros da lata leva negcios e rendas que a uns farta e a outros mata

1

Figura 6.3: PDF gerado por o ficheiro latex (teste 2). Pagina 1 de 2

Tejo que levas as guas correndo de par em par lava a cidade de mgoas leva as mgoas para o mar

Lava avenidas de vcios vielas de amores venais lava albergues e hospcios cadeias e hospitais

Afoga empenhos favores vs glrias, ocas palmas leva o poder dos senhores que compram corpos e almas

Leva nas guas as grades

Das camas de amor comprado desata abraos de lodo rostos corpos destroados lava-os com sal e iodo

Tejo que levas nas guas

Adriano Correia de Oliveira

0

Figura 6.4: PDF gerado por o ficheiro latex (teste 2). Pagina 2 de 2

= Ral tinha um Ioio

Manuel Antnio Pina, Suzana Ralha April 1, 2015

Letra

Ral tinha um ioio que ioioiava todo o dia quando o Ral fazia o ioio adormecia

E quando o Ral chorava porque o - no vinha o ioio embalava para baixo e para cima

Ral dormia e sonhava e quando sonhava sorria porque o io-io ioioiava nos sonhos que Ral via

Bando dos Gambozinos

Figura 6.5: PDF gerado por o ficheiro latex (teste 3)